Laporan GSLC 1 Deep Learning

Nama: Joshua Kevin Liem
NIM: 2802535572

A. Analisis Konseptual

A1. Efek Regularisasi pada Batch Normalization (slide 6-8)

- Sesuai dengan namanya, Batch Normalization bergantung pada gambar lain yang se-batch sehingga akan menghasilkan noise kecil karena hanya estimasi dari statistik yang sebenarnya. Noise ini yang mencegah model menghafal data training. Efek ini mirip Dropout yang menambah noise kecil. Hal ini yang membuat slide 8 menyebutkan bahwa Batch Normalization "acts like mild regularization" dan "often eliminates the need for Dropout".
- Kondisi dimana batch size terlalu kecil karena noise nya akan jadi terlalu berbeda sehingga nilai tiap gambar lebih ditentukan teman sebatchnya daripada isinya sendiri. Kondisi kedua yaitu jika BN digunakan bersamaan dengan Dropout (BN setelah Dropout) karena Dropout bekerja dengan cara mengubah variance data sehingga saat training BN akan membaca data dengan statistik variance yang besar. Hal ini menyebabkan normalisasinya menggunakan angka yang salah sehingga nanti saat tes accuracy nya akan turun (instabilitas pelatihan)

A.2. Degradasi Jaringan Dalam dan Formulasi Residual (slide 10-12)

- Hal ini karena error training-nya sendiri memburuk. Penyebabnya adalah optimizer gagal menemukan solusi identity itu, karena meniru identitas lewat tumpukan layer non-linear dan identitas hanya tercapai jika semua layer bernilai nyaris tepat secara bersamaan.
- Skip connection adalah menambah jalan pintas untuk input (x) dari layer sebelumnya sehingga layer saat ini hanya mempelajari selisih lalu nanti ditambahkan dengan input sebelumnya lewat jalan pintas $y = F(x) + x$ (Slide 11). Misal keluaran F(x) kecil, akan ditambah input sebelumnya sehingga y tidak akan meleset jauh. Efeknya saat backpropagation yaitu karena backpropagation rumusnya turunan (turunan F dan turunan x yaitu 1), jika ternyata pengaruh F kecil, masih ada jalan pintas yang tidak terpengaruh oleh F sehingga pesan dari y akan tetap sampai secara utuh sehingga dapat memitigasi fenomena vanishing gradient.

A.3. Feature Extraction vs. Fine-Tuning (slide 14-16)

- Jumlah trainable parameters: feature extraction hanya melatih `fc` (5.130 parameter), sedangkan fine-tuning layer 4 + fc melatih ±8,4 juta parameter.

- Kebutuhan data: parameter yang sedikit aman untuk data kecil, sedangkan makin banyak parameter yang dibuka, makin besar risiko overfitting dan makin banyak data yang diperlukan.
- Komputasi dan memori per epoch: feature extraction lebih ringan karena backpropagation berhenti di fc, sehingga gradient dan optimizer state backbone tidak perlu disimpan.
- Risiko destructive gradient updates: pada feature extraction backbone tidak tersentuh sehingga fitur bawaan aman. Pada fine-tuning, gradient besar dari head acak mengalir ke layer 4 dan dapat merusak weight pretrained.

- Kriteria praktis: pilih feature extraction jika data sedikit dan domain mirip ImageNet (Slide 15). Pilih fine-tuning jika data cukup banyak atau domain berbeda, dengan learning rate kecil dan unfreezing bertahap (Slide 16).

A.4. Kaidah Penerapan Data Augmentation (slide 20-22)

- Data Augmentation diterapkan untuk menambah variasi data untuk mengurangi overfitting. Augmentation hanya dipakai saat training karena tujuannya melatih model menghadapi variasi. Saat validasi dan test, tujuannya mengukur kemampuan model secara jujur dan konsisten, dan itu tidak bisa dilakukan kalau gambarnya diacak-acak. Kalo dilakukan Augmentasi maka nanti hasil test tidak bisa dibandingkan performa antar model.
- Contoh Augmentasi yang tidak cocok untuk dataset ini yaitu mengubah warna secara ekstrem. Klasifikasi ras sangat bergantung pada warna dan pola bulu, jika warna diubah maka gambar akan kehilangan fitur penting yang membedakan ras sehingga dapat terjadi label noise. Model nanti mempelajari misal gambar A tapi labelnya B karena gambar A dengan B tidak berbeda (fitur warna hilang) atau invariansi label.

A.5. Mitigasi Catastrophic Forgetting (slide 28-29)

- Terjadinya forgetting: weight pretrained ImageNet (pendeteksi garis, tekstur, bentuk) sudah baik. Saat layer 4 dibuka, gradient besar dari head fc yang masih acak mengalir mundur dan menimpa weight tersebut, sehingga representasi bawaan hilang.
- Differential learning rate: layer 4 diberi learning rate kecil (1e-4) dan fc lebih besar (1e-3). Strategi ini efektif karena fc acak harus belajar cepat, sedangkan layer4 sudah hampir benar sehingga cukup digeser sedikit. Update kecil menjaga weight tetap dekat dengan nilai pretrained.
- Gradual unfreezing: latih fc saja terlebih dahulu, lalu buka layer 4. Strategi ini efektif karena saat layer 4 dibuka, fc sudah cukup baik sehingga gradient yang mengalir ke backbone kecil dan terarah, bukan noise dari head acak.

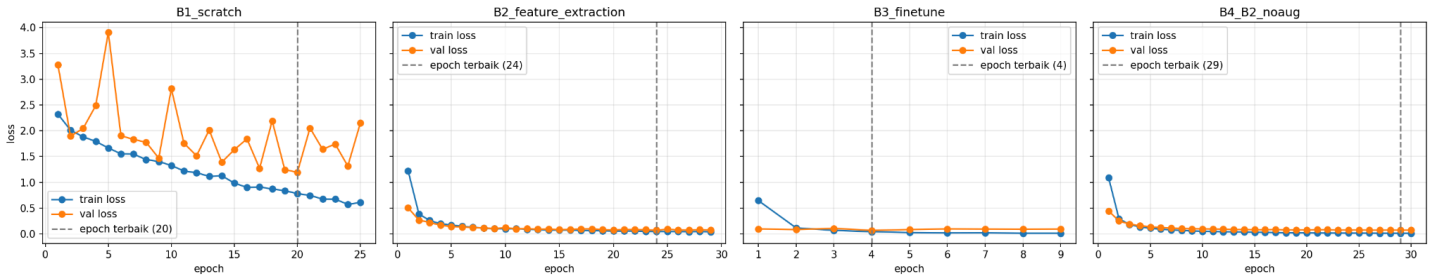
C1. Tabel Konsolidasi dan Visualisasi Pembelajaran

- Konfigurasi eksperimen: Dataset Oxford-IIIT Pet, 10 kelas (Abyssinian, Bengal, Persian, Russian Blue, Siamese, Beagle, Boxer, Chihuahua, Pug, Samoyed), 1.996 gambar, split stratified seed 42: train 1.397, validation 299, test 300. Arsitektur utama ResNet-18 (ImageNet pretrained), pembanding EfficientNet-B0. Protokol seragam: batch 32, AdamW (weight decay 1e-2), CrossEntropyLoss, early stopping pada validation loss (patience 5, maksimum 30 epoch), seed 42, Google Colab GPU T4.

Kondisi	**Trainable params**	**LR**	**Jumlah Epoch / best**	**Waktu (s)**	**s/epoch**	**Acc train**	**Acc val**	**Gap**	**Macro F1 test**
B1 From scratch, aug.	11.181.642	1e-3	25/20	364,1	14,56	0,7015	0,6221	0,0794	0,5946
B2 Feature extraction, aug.	5.130	1e-3	29/24	383,7	13,23	0,9928	0,9799	0,0129	0,9610

B3 Fine tuning layer 4 + fc aug	8.398.858	1e-4 (layer 4) 1e-3 (fc)	9/4	123,0	13,67	0,9971	0,9799	0,0172	0,9701
B4: B2 tanpa augmentation	5.130	1e-3	30/29	285,4	9,51	1,0000	0,9799	0,0201	0,9606
B5 EfficientNet-B0 fine tuning aug	1.142.202	1e-4 (features [7:]) 1e-3 (head)	20/15	270,1	13,51	1,0000	0,9933	0,0067	0,9835

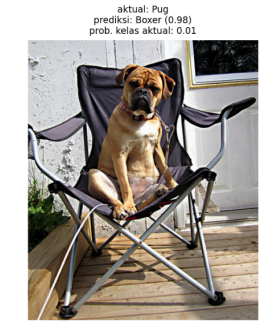
Tabel 1. Ringkasan kondisi B1-B5. Acc train dihitung ulang tanpa augmentation pada bobot terbaik; Gap = Acc train dikurangi Acc val. Bobot yang dievaluasi adalah bobot pada epoch dengan validation loss terendah. Waktu = total training sampai berhenti, termasuk evaluasi validasi tiap epoch.

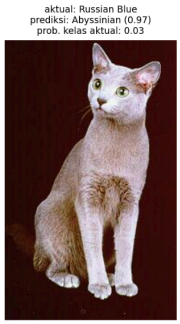


C2. Pembahasan Analisis Komparatif

- B1 terlihat dari val loss yang terus di atas dan menjauhi train loss juga menandakan overfitting. Skip connection membantu menstabilkan tapi dampak kurangnya data tetap lebih berdampak. B2 terlihat stabil dengan val loss yang stabil (gapnya tidak membesar) menandakan model aman dari overfitting karena yang dilatih hanya layer fc saja. B3 menunjukkan gap train-val yang lebih lebar daripada B2, konsisten dengan kapasitas ±8,4 juta parameter pada 1.397 citra. Val loss tidak meningkat dan val accuracy setara B2 sehingga fine-tuning tidak memberikan manfaat lebih pada kasus ini.
- Menurut saya performa yang dihasilkan B2 tidak lebih butuk dari B3 tapi B3 lebih beresiko karena gap nya lebih besar. Sedangkan B2 lebih stabil karena val loss turun secara perlahan (lebih mulus) dibanding B3 yang sejak awal sudah turun drastis dan nyaris datar.
- Augmentasi meredam kecenderungan menghafal train set, tetapi tidak meningkatkan generalisasi di eksperimen ini.
- EfficientNet-B0 (B5) mencapai Macro F1 test 0,9835, lebih tinggi 0,0134 daripada ResNet-18 B3 (0,9701), dengan trainable parameters 86% lebih sedikit (1,14 juta vs. 8,40 juta) dan total parameter sekitar 64% lebih sedikit. Waktu pelatihan total B5 lebih lama (270,1 vs. 123,0 s) akibat jumlah epoch yang lebih banyak.

C3. Failure Analysis









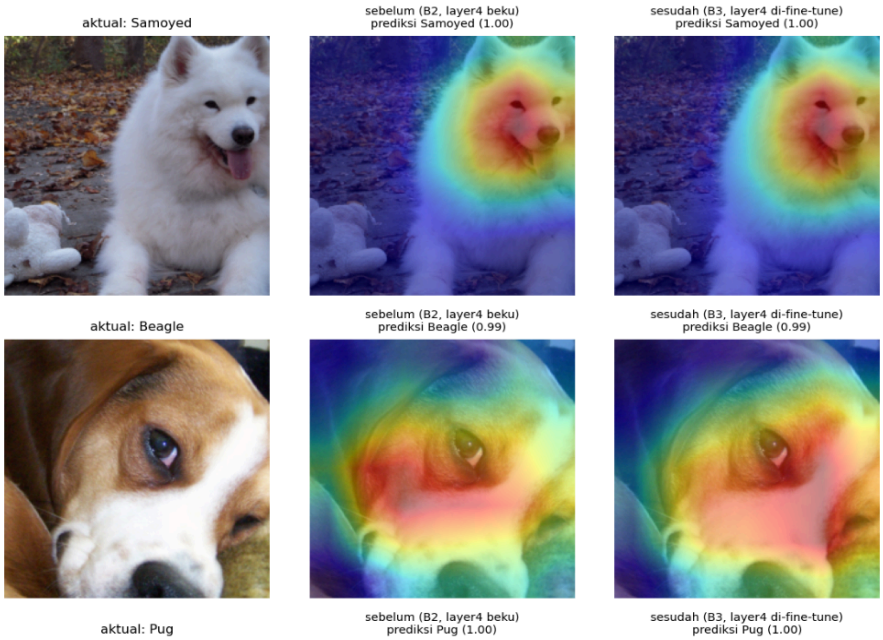


- Hipotesis saya untuk gambar pertama yaitu bukan kesalahan model melainkan kesalahan label karena menurut saya gambar 1 benar ras Boxer bukan Pug. Kesalahan prediksi gambar 2 kemungkinan disebabkan karena warna biru yang seharusnya menjadi fitur malah tidak terlihat. Gambar 3, 4, dan 5 salah prediksi karena gambar nya terpotong terlalu parah sehingga kesuluruhan fitur tidak dapat terbaca.

C4. Rekomendasi Rekayasa dan Batasan Eksperimen

- Saya memilih merekomendasikan menggunakan strategi pelatihan feature extraction dengan catatan kondisi bahwa domain gambar masih berada dekat dengan domain gambar ImageNet. Pada domain yang dekat dengan ImageNet, studi ini menunjukkan B2 mencapai akurasi validasi setara fine-tuning (B3) dengan 5.130 dibanding 8,4 juta trainable parameters. Jika domain jauh dari ImageNet, progressive fine-tuning (B3) dengan differential learning rate dan gradual unfreezing lebih sesuai karena fitur pada layer yang lebih dalam perlu disesuaikan (Slide 16, 28).

C5. Eksplorasi Tambahan



- Untuk B2 (representasi pretrained) dan B3 (setelah fine-tuning) menunjukkan fokus serupa pada wajah tanpa tanda bias latar belakang.

Referensi:

1. Materi kuliah Sesi 05: Advanced CNNs and Transfer Learning (Slide 5-30).
2. Kapoor, A., Gulli, A., Pal, S., Chollet, F. (2022). Deep Learning with TensorFlow and Keras. Packt Publishing.
3. *Li et al. (2019), "Understanding the Disharmony between Dropout and Batch Normalization by Variance Shift"*.

Keterangan AI:

- AI yang digunakan: Claude
- Ruang lingkup bantuan: Membantu membuat code dan debugging, memberi struktur laporan, membantu verifikasi pengetahuan, membantu membuat dokumen requirement dan readme.
- Cara memverifikasi: Menjalankan seluruh code di Colab, mencocokan jumlah parameter dan output dengan panduan tugas, mencocokan angka dengan CSV, memahami code.